

Vectorización y Análisis de Sentimiento de Reseñas de Hoteles Tripadvisor

Alejandra Paola Castillo Gallegos

Matrícula: 1801137

Materia: Procesamiento y Clasificación de Datos

Maestría en Ciencia de Datos

Facultad de Ciencias Físico Matemáticas, Universidad Autónoma de Nuevo León

I. INTRODUCTION

La reputación de las propiedades hoteleras es un factor decisivo que influye al momento de elegir un hotel, más añadiendo las tendencias de plataformas digitales y uso de reseñas, han convertido las reseñas digitales en una herramienta indispensable [Gatica Santamaría Angelina; Abreu Rangel, 2024] para la decisión de compra de todo vacacionista buscando la mejor opción. El análisis del sentimiento es el proceso automático de identificar si la retroalimentación de un cliente es positiva o negativa, obteniendo una única fuente que permite evaluar las reseñas por contenido y contexto, no solo por la calificación general. El análisis de sentimiento basado en aspectos se puede utilizar para analizar los comentarios de los clientes asociándolos con diferentes aspectos del hotel [Coello Vallecillo, 2023], lo cual nos ayudará a transformar opiniones no estructuradas en información cuantificable.

II. OBJETIVO GENERAL

El objetivo general del proyecto es analizar las reseñas de hoteles de TripAdvisor mediante técnicas de procesamiento de lenguaje natural, utilizando la vectorización TF-IDF y métodos de análisis de sentimiento para estudiar la relación entre el contenido textual de las opiniones y las calificaciones numéricas otorgadas por los usuarios.

III. DESCRIPCIÓN DE LOS DATOS

Para el desarrollo del análisis se utilizó el conjunto de datos TripAdvisor Hotel Reviews, integrado por reseñas escritas por usuarios sobre su experiencia en distintos hoteles. La base original contiene 20,491 observaciones y dos variables principales:

- **Review:** texto de la reseña escrita por el usuario.
- **Rating:** calificación numérica asignada al hotel, expresada en una escala de 1 a 5 estrellas.

Durante la revisión de calidad de los datos no se encontraron valores faltantes ni reseñas duplicadas, por lo que se conservaron las 20,491 observaciones para el análisis. La calificación media fue de 3.95 estrellas, con una desviación estándar de 1.23, una mediana de 4 y valores comprendidos entre 1 y 5. La distribución de las calificaciones fue la siguiente:

Calificación	Número de reseñas	Porcentaje aproximado
1 estrella	1,421	6.93%
2 estrellas	1,793	8.7%
3 estrellas	2,184	10.66%
4 estrellas	6,039	29.47%
5 estrellas	9,054	44.19%

Se observa un predominio de las calificaciones altas, ya que aproximadamente el 73.66% de las reseñas recibió cuatro o cinco estrellas. Esto indica que el conjunto de datos presenta un desbalance hacia opiniones favorables. Para facilitar el análisis de sentimiento, las calificaciones se agruparon en tres categorías:

- **Negativo:** calificaciones de 1 o 2 estrellas.
- **Neutral:** calificaciones de 3 estrellas.
- **Positivo:** calificaciones de 4 o 5 estrellas.

Con esta clasificación se obtuvieron 3,214 reseñas negativas, equivalentes al 15.68%; 2,184 reseñas neutrales, equivalentes al 10.66%; y 15,093 reseñas positivas, equivalentes al 73.66%. En cuanto a la extensión del contenido, las reseñas tuvieron una longitud promedio de 722.9 caracteres y 104.38 palabras. La mediana fue de 77 palabras, mientras que la reseña más corta contenía 7 palabras y la más extensa alcanzó 1,931 palabras. Esta variabilidad muestra que el conjunto incluye tanto comentarios breves como narraciones detalladas sobre la experiencia de hospedaje.

IV. METODOLOGÍA

El análisis se desarrolló mediante un proceso de procesamiento de lenguaje natural compuesto por las siguientes etapas.

A. Preparación de datos

Inicialmente se identificaron las variables correspondientes al texto de la reseña y a la calificación. Posteriormente, la variable Rating se convirtió a formato numérico y se verificó la existencia de valores faltantes, registros duplicados y calificaciones fuera del intervalo de 1 a 5. También se calcularon medidas descriptivas sobre la longitud de las reseñas, considerando tanto el número de caracteres como el número de palabras. La exploración permitió conocer la distribución de las calificaciones e identificar el desbalance existente entre las clases de sentimiento.

B. Preprocesamiento del texto

Las reseñas fueron normalizadas antes de construir su representación numérica. El preprocesamiento incluyó:

- Conversión de todo el texto a minúsculas.
- Eliminación de etiquetas HTML.
- Eliminación de direcciones URL.
- Eliminación de números, signos de puntuación y caracteres especiales.
- Corrección de espacios repetidos.
- Tokenización del texto.
- Eliminación de palabras vacías en inglés.
- Lematización de los términos.
- Eliminación de tokens con longitud menor a dos caracteres.

A diferencia de un procedimiento convencional de eliminación de palabras vacías, se conservaron términos de negación como not, no, nor y never, debido a que pueden modificar completamente el sentido de una oración. Por ejemplo, las expresiones clean room y not clean room transmiten sentimientos diferentes.

C. Vectorización TF-IDF

Para representar numéricamente las reseñas se utilizó el método **TF-IDF**, que asigna un peso a cada término en función de su frecuencia dentro de una reseña y de su importancia respecto al conjunto completo de documentos. Se configuró un vocabulario máximo de 5,000 características, considerando unigramas y bigramas. Los unigramas representan términos individuales, mientras que los bigramas permiten conservar combinaciones relevantes como not recommend, nothing special o great hotel. Los principales parámetros empleados fueron:

- max_features = 5000
- min_df = 5
- max_df = 0.90
- ngram_range = (1, 2)
- sublinear_tf = True
- Normalización L2

La eliminación de términos con frecuencias extremadamente bajas o altas permitió reducir ruido y conservar expresiones con mayor capacidad descriptiva.

D. Estudio de las propiedades vectoriales

Una vez construida la matriz TF-IDF, se analizaron su dimensionalidad, densidad, esparsidad, número de valores distintos de cero, norma L2 y cantidad promedio de características activas por reseña. También se calcularon los términos con mayor peso TF-IDF promedio en el corpus completo y dentro de cada categoría de sentimiento.

E. Análisis de sentimiento con VADER

Como método léxico no supervisado se utilizó **VADER**, aplicado directamente sobre las reseñas originales. Este método produce un valor denominado compound, comprendido entre -1 y 1 , donde los valores negativos indican

una orientación desfavorable y los positivos una orientación favorable. La clasificación se realizó de la siguiente manera:

- $compound \geq 0.05$: sentimiento positivo.
- $compound \leq -0.05$: sentimiento negativo.
- Valores intermedios: sentimiento neutral.

El resultado de VADER se comparó con la categoría obtenida a partir de la calificación numérica.

F. Modelo supervisado

Adicionalmente, se entrenó un modelo de **regresión logística multinomial** utilizando los vectores TF-IDF como variables predictoras y el sentimiento derivado de las estrellas como variable objetivo. Los datos se dividieron en:

- 80% para entrenamiento.
- 20% para prueba.

La división se realizó de manera estratificada para conservar la proporción de las clases. Se utilizó el parámetro `class_weight="balanced"` para reducir parcialmente el efecto del desbalance de las categorías. El desempeño se evaluó mediante exactitud, precisión, recall, F1-score y matrices de confusión.

G. Similitud entre reseñas

Finalmente, se empleó la similitud coseno para identificar reseñas con representaciones TF-IDF semejantes. Esta medida compara la orientación de los vectores y genera valores cercanos a 1 cuando dos reseñas utilizan vocabulario y expresiones similares.

V. RESULTADOS

A. Propiedades de la representación TF-IDF

La matriz TF-IDF obtenida tuvo dimensiones de **20,491 filas por 5,000 columnas**, correspondientes a las reseñas y características textuales, respectivamente. En total, la matriz podía contener 102,455,000 valores, pero únicamente **1,716,534** fueron distintos de cero. La densidad de la matriz fue de **0.01675**, mientras que la esparsidad alcanzó **0.98325**, equivalente al **98.32%**. Esto significa que la mayoría de las posiciones de la matriz fueron cero, una propiedad esperada en la representación de documentos mediante bolsa de palabras y TF-IDF, debido a que cada reseña utiliza solamente una pequeña fracción del vocabulario total. Cada reseña presentó, en promedio, **83.77 características activas**. La mediana fue de 69, el primer cuartil de 46 y el tercer cuartil de 103. La reseña con menor representación tuvo 3 características activas, mientras que la de mayor tamaño presentó 843. La norma L2 promedio fue exactamente igual a 1, debido al procedimiento de normalización aplicado por el vectorizador. Esta normalización permitió comparar reseñas de distintas longitudes mediante similitud coseno sin que los documentos extensos dominaran únicamente por contener más palabras.

B. Términos más relevantes del corpus

Los términos con mayor TF-IDF promedio en el conjunto completo fueron:

- *hotel*
- *room*
- *not*
- *great*
- *staff*
- *stay*
- *good*
- *location*
- *night*
- *nice*
- *stayed*

Estos resultados son coherentes con la temática del conjunto, debido a que la mayoría de las opiniones describen habitaciones, personal, ubicación, noches de estancia y calidad general del hotel. La presencia de *not* entre los términos con mayor peso confirma la importancia de haber conservado las negaciones durante el preprocesamiento. En las reseñas negativas, los términos con mayor peso promedio incluyeron *not*, *room*, *hotel*, *no*, *night*, *stay*, *service*, *time* y *told*. En las reseñas neutrales destacaron *room*, *hotel*, *not*, *good*, *nice*, *location*, *clean* y *great*. En las reseñas positivas aparecieron con mayor importancia *hotel*, *room*, *great*, *staff*, *stay*, *location*, *good* y *nice*. Aunque algunos términos se repiten en las tres categorías, su importancia individual no permite determinar por sí sola el sentimiento. Palabras como *room*, *hotel* y *location* describen el tema de la reseña, mientras que la orientación depende de su combinación con adjetivos, negaciones y expresiones contextuales.

C. Resultados del análisis con VADER

VADER clasificó:

- **18,831 reseñas como positivas**
- **1,569 reseñas como negativas**
- **91 reseñas como neutrales**

En términos porcentuales, aproximadamente el **91.9%** de las reseñas fue clasificado como positivo, el **7.66%** como negativo y únicamente el **0.44%** como neutral. La coincidencia global entre el sentimiento identificado por VADER y la clasificación derivada de las estrellas fue de **79.52%**. La matriz de comparación mostró los siguientes resultados:

Sentimiento estrellas	VADER negativo	VADER neutral	VADER positivo
Negativo	1,304	61	1,849
Neutral	167	13	2,004
Positivo	98	27	14,978

VADER identificó correctamente la mayoría de las reseñas positivas, con un recall de **0.99** para esta clase. Sin embargo, su capacidad para reconocer las categorías negativa y neutral fue considerablemente menor. Para la clase negativa obtuvo una precisión de **0.83**, un recall de **0.41** y un F1-score de **0.55**. Esto indica que, cuando VADER asignó una etiqueta

negativa, generalmente fue correcta, pero dejó sin detectar una proporción importante de reseñas realmente negativas. La clase neutral presentó el desempeño más bajo, con precisión de **0.14**, recall de **0.01** y F1-score de **0.01**. De las 2,184 reseñas neutrales, solo 13 fueron identificadas correctamente por VADER. En términos globales, VADER obtuvo:

- Exactitud: **0.7952**
- Precisión macro: **0.5898**
- Recall macro: **0.4680**
- F1-score macro: **0.4799**

La diferencia entre la exactitud y el F1 macro refleja el efecto del desbalance de clases. La elevada exactitud se encuentra influida principalmente por la correcta identificación de la clase positiva, que es la categoría mayoritaria.

D. Relación entre VADER y las calificaciones

El puntaje compound mostró una tendencia creciente conforme aumentaba el número de estrellas.

Rating	Compound promedio	Mediana
1	-0.1431	-0.3818
2	0.3885	0.7779
3	0.7658	0.9490
4	0.9346	0.9776
5	0.9557	0.9828

Las reseñas de una estrella fueron las únicas con un promedio negativo. No obstante, las reseñas de dos estrellas presentaron un promedio positivo de 0.3885, lo que indica que VADER interpretó favorablemente numerosos comentarios que, en términos de calificación, representaban una experiencia negativa. La correlación de Spearman entre la calificación y el puntaje compound fue de 0.4636. Este resultado representa una relación positiva moderada: en general, las calificaciones altas se relacionan con un sentimiento textual más favorable, pero la relación no es perfecta. Se detectaron 1,947 contradicciones fuertes, equivalentes al 9.5% del conjunto. Estas contradicciones correspondieron a reseñas positivas según la calificación, pero negativas según VADER o reseñas negativas según las estrellas, pero positivas según VADER. La mayor parte de estos casos estuvo constituida por reseñas de una o dos estrellas que incluían palabras favorables al describir algún aspecto particular del hotel, aunque la evaluación general fuera negativa.

E. Resultados de la regresión logística

El modelo de regresión logística con TF-IDF alcanzó una exactitud de **0.8185** sobre el conjunto de prueba, formado por 4,099 reseñas. Las métricas por clase fueron:

Clase	Precisión	Recall	F1-score
Negativo	0.74	0.81	0.77
Neutral	0.34	0.51	0.40
Positivo	0.95	0.87	0.91

El modelo obtuvo:

- Precisión macro: 0.6776.

- Recall macro: 0.7259.
- F1-score macro: 0.6950.
- F1-score ponderado: 0.83.

La regresión logística superó a VADER tanto en exactitud como en las métricas macro. La mejora fue especialmente importante en las clases negativa y neutral. Los términos con mayor influencia en la identificación de reseñas negativas fueron not, terrible, worst, dirty, no, rude, poor, bad, uncomfortable y el bigrama not recommend. Para la clase neutral destacaron ok, average, nothing special, decent, bit, not bad, fine, clean y nice. En la clase positiva sobresalieron great, excellent, loved, wonderful, perfect, fantastic, great hotel, quiet, comfortable, amazing y definitely stay. Estos resultados muestran que el modelo aprendió expresiones coherentes con cada categoría y que los bigramas aportaron información adicional para representar opiniones completas.

VI. DISCUSIÓN

Los resultados muestran que existe una relación entre la calificación otorgada y el sentimiento expresado en el texto; sin embargo, esta relación no es completamente directa. La correlación de Spearman de 0.4636 indica una asociación positiva moderada, lo que significa que las reseñas con más estrellas suelen utilizar expresiones más favorables, pero también existen numerosos casos mixtos o contradictorios. Uno de los hallazgos principales fue la marcada tendencia de VADER a clasificar las reseñas como positivas. Mientras que el 73.66% de las observaciones correspondía a la clase positiva según las estrellas, VADER asignó esta categoría al 91.90% de los textos. Este comportamiento puede explicarse porque muchas reseñas negativas mencionan aspectos positivos antes de expresar las causas de insatisfacción. Por ejemplo, una persona puede destacar que el hotel tenía una buena ubicación o que el personal era amable, pero posteriormente señalar problemas graves de limpieza, ruido, cobros o servicio. Un método basado en lexicones puede acumular las palabras positivas y producir un valor compound elevado, aunque la conclusión general de la reseña sea desfavorable. Esto fue particularmente visible en las reseñas de dos estrellas, cuyo puntaje compound promedio fue positivo. Por tanto, la calificación numérica parece resumir la evaluación global de la experiencia, mientras que VADER evalúa la polaridad de las palabras y oraciones individuales. La categoría neutral fue la más difícil de identificar. Solo 13 de las 2,184 reseñas neutrales fueron reconocidas correctamente por VADER. Esto se debe a que una calificación de tres estrellas no implica necesariamente un texto lingüísticamente neutral. Una reseña de tres estrellas puede contener una mezcla intensa de opiniones positivas y negativas, mientras que VADER puede inclinarse hacia cualquiera de los dos extremos. La regresión logística con TF-IDF obtuvo un rendimiento superior porque aprendió directamente la relación entre el vocabulario de las reseñas y las etiquetas derivadas de las estrellas. A diferencia de VADER, el modelo fue capaz de asociar expresiones propias del dominio hotelero con cada categoría. El uso de `class_weight="balanced"` permitió mejorar la sensibilidad en las clases minoritarias. El recall de la clase

negativa aumentó de 0.41 con VADER a 0.81 con regresión logística. Para la clase neutral aumentó de 0.01 a 0.51, aunque su precisión permaneció relativamente baja. El F1-score macro de la regresión logística fue de 0.6950, considerablemente mayor que el valor de 0.4799 obtenido por VADER. Esto indica que el modelo supervisado presentó un comportamiento más equilibrado entre las tres categorías. La representación TF-IDF resultó adecuada por su interpretabilidad y eficiencia. Permitted identificar los términos más representativos de cada sentimiento y generar una matriz manejable de 5,000 características. Su elevada esparsidad no constituye un problema, sino una característica natural de este tipo de representación. Sin embargo, TF-IDF también presenta limitaciones. No comprende completamente el orden de las palabras, la ironía, el sarcasmo ni las dependencias de largo alcance. Aunque los bigramas conservaron algunas expresiones relevantes, el método continúa representando el texto principalmente a partir de frecuencias. Otra limitación importante es que las etiquetas de sentimiento fueron construidas a partir de las estrellas. Una calificación de tres estrellas fue considerada neutral, aunque el texto pudiera expresar una opinión positiva con reservas o una experiencia negativa parcialmente compensada. Por ello, las estrellas deben interpretarse como una aproximación al sentimiento global y no como una verdad lingüística absoluta. Finalmente, el desbalance de clases influyó en las métricas. La exactitud por sí sola habría presentado una visión demasiado favorable del desempeño, debido al predominio de reseñas positivas. Por esta razón fue necesario considerar precisión, recall y F1-score macro.

VII. CONCLUSIONES

El análisis permitió representar satisfactoriamente las reseñas de hoteles mediante TF-IDF y estudiar las propiedades de los vectores obtenidos. La matriz resultante estuvo formada por 20,491 documentos y 5,000 características, con una esparsidad del 98.32%, lo que confirma que cada reseña utiliza solo una proporción reducida del vocabulario total. La conservación de las negaciones y la inclusión de unigramas y bigramas fueron decisiones importantes. Expresiones como not recommend, nothing special y great hotel proporcionaron información útil para diferenciar las categorías de sentimiento. Los términos más influyentes del modelo mostraron una correspondencia clara con cada clase. Palabras como terrible, worst, dirty y rude se asociaron con opiniones negativas; ok, average y decent con opiniones neutrales; y great, excellent, wonderful y perfect con opiniones positivas. La comparación entre el contenido textual y las calificaciones mostró que sí existe una relación entre ambas variables, aunque no es perfecta. La correlación de Spearman de 0.4636 evidenció una asociación positiva moderada entre las estrellas y el puntaje de sentimiento de VADER. VADER alcanzó una coincidencia global del 79.52%, pero presentó una fuerte tendencia a clasificar las reseñas como positivas. Su rendimiento fue especialmente bajo en la identificación de opiniones neutrales y dejó sin reconocer una proporción considerable de reseñas negativas. La regresión logística con TF-IDF obtuvo mejores resulta-

dos, con una exactitud de 81.85% y un F1-score macro de 0.6950. Además, presentó un comportamiento más equilibrado entre las clases y mejoró notablemente el reconocimiento de los sentimientos negativo y neutral. Por lo tanto, para este conjunto de datos, el método supervisado basado en TF-IDF y regresión logística fue más adecuado que VADER para predecir el sentimiento asociado con las calificaciones numéricas. No obstante, los resultados también demuestran que una reseña no siempre expresa un único sentimiento. Los usuarios pueden reconocer aspectos positivos y negativos dentro de una misma experiencia, mientras que la calificación representa una evaluación global. Las 1,947 contradicciones fuertes identificadas reflejan esta complejidad. En conclusión, los métodos empleados permitieron transformar las reseñas en información cuantitativa, identificar patrones lingüísticos asociados con la satisfacción de los usuarios y comparar el sentimiento textual con las calificaciones. El análisis confirma la utilidad de TF-IDF para tareas interpretables de clasificación de texto, aunque también evidencia la necesidad de métodos más sensibles al contexto para comprender adecuadamente opiniones mixtas, ironía y relaciones complejas entre palabras.

REFERENCES

- [Coello Vallecillo, 2023] Coello Vallecillo, R. E. (2023). Análisis de sentimiento basado en los aspectos de las reseñas de una cadena de restaurantes en honduras.
- [Gatica Santamaría Angelina; Abreu Rangel, 2024] Gatica Santamaría Angelina; Abreu Rangel, Lucia [; Landa Acosta, K. Y. S. E. D. (2024). El impacto de las reseñas digitales en la reputación de los hoteles de cinco estrellas de cancún.